

KHO DỮ LIỆU VÀ KỸ THUẬT KHAI PHÁ

BÀI GIẢNG

**DÀNH CHO SINH VIÊN CÔNG NGHỆ
THÔNG TIN**

NGUYỄN QUỲNH CHI

GIỚI THIỆU

Học phần Kho dữ liệu và kỹ thuật khai phá cung cấp phương pháp luận và lý thuyết cơ sở dữ liệu về việc xây dựng một kho dữ liệu và ứng dụng vào xử lý phân tích trực tuyến, đồng thời cung cấp các kiến thức cơ bản về các phương pháp tích hợp cơ sở dữ liệu và các phương pháp khai phá dữ liệu để hỗ trợ cho hệ trợ giúp quyết định. Do đối tượng là sinh viên năm cuối của đại học nên chỉ trình bày những phương pháp khai phá cơ bản.

Đối tượng chính của bài giảng này là sinh viên ngành Công nghệ thông tin hệ đại học, ngoài ra sinh viên các hệ và chuyên ngành khác có thể dùng làm tài liệu tham khảo nếu cần. Để hiểu sâu thêm những kiến thức được trình bày trong bài giảng này, sinh viên cần đọc thêm sách được nêu ra trong phần tài liệu tham khảo. Sinh viên cần hoàn thành các môn học: Cơ sở dữ liệu, kỹ thuật lập trình, có khả năng làm việc với một hệ quản trị CSDL, nhập môn xác suất thống kê trước khi tham gia học môn học này.

Đây là một môn học tính điểm trung bình sau khi kết thúc cuối kỳ học, trong đó kiểm tra cuối kỳ chiếm 70%, kiểm tra giữa kỳ chiếm 20%, quá trình tham dự trên lớp chiếm 10%.

Tổng số gồm 3 tín chỉ trong đó 44 tiết lý thuyết giảng trên lớp, 8 tiết cho việc giảng viên giải đáp thắc mắc về bài tập và 2 tiết ôn tập trước khi thi cuối kỳ.

Yêu cầu đọc sách để chuẩn bị bài và làm bài tập lớn theo hướng dẫn của giảng viên trước mỗi buổi tham gia lớp học. Nói chung sinh viên được khuyến khích đặt các câu hỏi và phát biểu ý kiến riêng với những vấn đề đặt ra trong quá trình nghe giảng trên lớp, tránh thái độ thụ động ngồi nghe.

Nội dung của môn học sẽ được trình bày trong mục lục của bài giảng.

Mục lục

CHƯƠNG I: Giới thiệu về kho dữ liệu và khai phá dữ liệu.....	7
1.1 Khai phá dữ liệu là gì.....	8
1.2 Các loại dữ liệu và kiểu mẫu dữ liệu được khai phá.....	8
1.3 Các bài toán và phương pháp cơ bản trong khai phá dữ liệu.....	10
Định nghĩa bài toán phân loại.....	10
Định nghĩa bài toán phân cụm.....	11
Định nghĩa bài toán phát hiện luật kết hợp.....	12
Bài toán phân loại cho dữ liệu hồi quy.....	12
Phát hiện sự sai lệch hay dị thường.....	13
Khai phá dữ liệu và Nguyên lý quy nạp.....	13
1.4 Sự tích hợp của khai phá dữ liệu với cơ sở dữ liệu hay kho dữ liệu.....	14
Vai trò của khai phá dữ liệu đối với quá trình phát hiện tri thức từ dữ liệu.....	14
Các bước của quá trình phát hiện tri thức từ dữ liệu.....	14
Các chuyên ngành khác liên quan tới khai phá dữ liệu.....	16
So sánh khai phá dữ liệu với phân tích thống kê.....	16
So sánh khai phá dữ liệu với cơ sở dữ liệu.....	17
So sánh khai phá dữ liệu với công nghệ kho dữ liệu.....	17
Kiến trúc của một mô tơ phân tích trực tuyến (OLAM).....	17
So sánh Cơ sở dữ liệu, xử lý phân tích trực tuyến và khai phá dữ liệu.....	18
1.5 Ứng dụng của kho dữ liệu và khai phá dữ liệu.....	21
Ứng dụng của bài toán phân lớp (phân loại).....	21
Ứng dụng của bài toán phân cụm.....	22
Ứng dụng của bài toán phát hiện luật kết hợp.....	22
Những vấn đề chính trong lĩnh vực công nghệ kho dữ liệu và khai phá dữ liệu.....	23

Câu hỏi ôn tập chương 1.....	24
Chương 2: Các công nghệ và kỹ thuật tích hợp cơ sở dữ liệu.....	26
2.1 Giới thiệu Mô hình dữ liệu mở rộng XML.....	26
Giới thiệu về ngôn ngữ XML (Extensible Markup Language).....	26
Một hệ thống XML điển hình.....	27
Cú pháp của XML.....	28
Khai báo kiểu văn bản – Data Type Declaration (DTD).....	31
Nhắc lại kiến thức về mô hình thực thể liên kết mở rộng.....	39
Kiến trúc tích hợp nhiều cơ sở dữ liệu.....	46
Kỹ thuật chuyển đổi lược đồ quan hệ sang mô hình thực thể liên kết mở rộng.....	46
Ví dụ về việc chuyển đổi từ lược đồ quan hệ sang mô hình thực thể liên kết.....	49
2.3 Tích hợp các lược đồ dữ liệu.....	53
Khái niệm về tích hợp dữ liệu.....	53
Các bước tích hợp ngữ nghĩa dữ liệu.....	54
Bài thực hành.....	65
2.4 Chuyển đổi và tích hợp dữ liệu.....	67
Phương pháp luận cho công nghệ kho dữ liệu và OLAP.....	67
Các cách chuyển đổi dữ liệu.....	67
Một ví dụ về việc chuyển đổi.....	71
Tích hợp dữ liệu.....	75
Câu hỏi ôn tập chương 2.....	81
Chương 3: Công nghệ kho dữ liệu và xử lý phân tích trực tuyến.....	83
3.1 Khái niệm về kho dữ liệu.....	83
3.2 Mô hình dữ liệu đa chiều.....	86
3.3 Kiến trúc của kho dữ liệu.....	95

3.4 Cài đặt kho dữ liệu.....	97
3.5 Liên hệ công nghệ kho dữ liệu với khai phá dữ liệu.....	104
3.6 Xây dựng kho dữ liệu với mục đích hỗ trợ quyết định (DSS).....	106
Nhắc lại một chút về khái niệm kho dữ liệu và những tác nhân liên quan.....	106
Các giai đoạn xây dựng.....	106
Thiết kế cơ sở dữ liệu với lược đồ hình sao.....	109
Nghiên cứu xây dựng một kho dữ liệu.....	110
Câu hỏi ôn tập chương 3.....	114
Chương 4: Khai phá dữ liệu.....	116
4.1 Tiền xử lý dữ liệu trước khi khai phá.....	116
Khái niệm về dữ liệu.....	116
Tiền xử lý dữ liệu.....	124
4.2 Phương pháp khai phá bằng luật kết hợp.....	129
Nguồn gốc của khai phá luật kết hợp.....	129
Các ứng dụng của luật kết hợp.....	129
Khái niệm cơ bản trong bài toán tìm luật kết hợp.....	130
Cách tiếp cận theo kiểu vét cạn (Brute-force approach).....	130
Khai phá luật kết hợp với cách tiếp cận hai bước.....	132
Phương thức giảm số lượng các ứng cử viên: thuật toán Apriori.....	133
Một phương pháp sinh tập các mặt hàng thường xuyên FP-growth.....	139
Sinh luật kết hợp.....	143
4.3 Phương pháp cây quyết định.....	145
Những khái niệm cơ bản trong bài toán phân loại.....	145
Phương pháp phân loại bằng cây quyết định.....	146
Các thuật toán tìm cây quyết định.....	149

Đánh giá các mô hình phân loại.....	160
4.4 Phương pháp phân nhóm và phân đoạn.....	164
Khái niệm về phân tích phân cụm.....	164
Độ đo trong phân cụm.....	166
Phân loại phân cụm.....	170
Phương pháp phân cụm.....	173
Câu hỏi ôn tập chương 4.....	178
Tài liệu tham khảo.....	188

PTIT

CHƯƠNG I: Giới thiệu về kho dữ liệu và khai phá dữ liệu

Vấn đề bùng nổ về dữ liệu: khi các công cụ thu thập dữ liệu tự động và công nghệ về cơ sở dữ liệu đã trở nên hoàn thiện, một lượng lớn dữ liệu được thu thập và lưu trữ trong những các cơ sở dữ liệu, kho dữ liệu và các kho lưu trữ thông tin khác.

Lúc này, chúng ta đang có quá nhiều dữ liệu, chưa mang tính phục vụ có mục đích cho người sử dụng. Chúng ta đang thiếu tri thức, dữ liệu đã qua xử lý và phục vụ riêng cho mục đích của người sử dụng. Vấn đề là làm thế nào để khai thác tri thức từ đồng dữ liệu khổng lồ hiện đang có trong tay.

Giải pháp cho việc khai phá ra tri thức chính là sự ra đời của công nghệ kho dữ liệu và các phương pháp khai phá dữ liệu. Giải pháp này liên quan tới những khía cạnh sau đây:

- Công nghệ để xây dựng một kho dữ liệu lớn và các phương thức để xử lý phân tích trực tuyến (sẽ nghiên cứu trong những bài học sau)
- Trích lọc ra tri thức có ích cho con người bao gồm các luật, thể chế, mẫu, và các ràng buộc từ khối lượng lớn dữ liệu của một hay nhiều cơ sở dữ liệu có kích cỡ lớn.

Các lý do cần khai phá dữ liệu trên quan điểm thương mại trong thế giới thực.

- Rất nhiều dữ liệu đã được thu thập trong thế giới thực và được lưu trữ một cách hệ thống trong các kho dữ liệu bao gồm:
 - o Các dữ liệu trên web, các dữ liệu thương mại điện tử
 - o Các dữ liệu mua bán tại các cửa hàng, gian hàng trong siêu thị
 - o Các dữ liệu của giao dịch ngân hàng, thẻ tín dụng
- Máy tính trở nên rẻ hơn và có sức mạnh xử lý dữ liệu hơn
- Sức ép cạnh tranh mạnh mẽ hơn: cần cung cấp các dịch vụ tốt hơn và tùy biến với khách hàng hơn (nhất là trong quan hệ với khách hàng)

Các lý do cần khai phá dữ liệu trên quan điểm khoa học

- Các dữ liệu được thu thập và lưu trữ với tốc độ rất nhanh (GB/h) thông qua
 - o Bộ cảm biến (sensor) điều khiển từ xa trên các trạm vệ tinh
 - o Kính viễn vọng quan sát bầu trời
 - o Dùng công cụ microarray để sinh ra dữ liệu thể hiện đặc tính của gene (gene expression data)

- Dùng các bộ mô phỏng khoa học để tạo ra hàng tera byte dữ liệu
- Các kỹ thuật truyền thống không còn khả thi cho lượng lớn các dữ liệu thô
- Các kỹ thuật khai phá dữ liệu có thể sẽ giúp ích được các nhà khoa học hơn trong các công việc
 - Phân loại và phân mảnh dữ liệu
 - Hình thành các giả thuyết trong nghiên cứu khoa học

1.1 Khai phá dữ liệu là gì

Khai phá dữ liệu (phát hiện tri thức trong cơ sở dữ liệu sẵn có) là việc trích lọc ra những thông tin có ích (không hiển nhiên, không tường minh, không biết trước, và có ích một cách tiềm năng), những mẫu dữ liệu trong các cơ sở dữ liệu lớn.

Khai phá dữ liệu có một số tên gọi khác khi được sử dụng khi được đề cập đến trong cuộc sống cũng như trong sách và tạp chí khoa học như:

- Khám phá tri thức (knowledge discovery) trong cơ sở dữ liệu (thường được viết tắt theo tiếng anh là KDD).
- Trích lọc tri thức
- Phân tích mẫu/dữ liệu
- Khảo cổ dữ liệu
- Tri thức kinh doanh (business intelligence) và còn nhiều tên khác nữa ít dùng.

Xem xét một ví dụ sau để phân biệt khái niệm khai phá dữ liệu với các khái niệm trong cơ sở dữ liệu, cái mà dễ nhầm tưởng là khai phá dữ liệu

Những xử lý không phải là khai phá dữ liệu	Những xử lý là khai phá dữ liệu
Tra cứu số điện thoại trong danh bạ điện thoại	Xác định những tên được cho là phổ biến ở một địa danh cụ thể nào đó
Truy vấn một mô tơ tìm kiếm thông tin trên Web liên quan tới từ “Amazon”	Gộp nhóm các tài liệu giống nhau được trả về bởi công cụ tìm kiếm thông tin dựa vào ngữ cảnh của chúng (ví dụ như rừng Amazon, hay vùng miền Amazon.com)

1.2 Các loại dữ liệu và kiểu mẫu dữ liệu được khai phá

Khi thực hiện một công việc khai phá dữ liệu, để đưa ra các quyết định cần thiết cho công việc khai phá, chúng ta cần xác định những yếu tố sau:

- Loại cơ sở dữ liệu cần khai phá

Các loại cơ sở dữ liệu có thể dùng cho khai phá bao gồm cơ sở dữ liệu quan hệ, cơ sở dữ liệu giao dịch, hướng đối tượng, cơ sở dữ liệu quan hệ- đối tượng, không gian, cơ sở dữ liệu văn bản, chuỗi thời gian, đa phương tiện, cơ sở dữ liệu hỗn tạp, cơ sở dữ liệu luật, cơ sở dữ liệu Web, và các loại cơ sở dữ liệu khác nữa.

- Loại tri thức cần phát hiện ra

Bao gồm tri thức miêu tả đặc điểm của các cá thể trong tập cá thể đang xét, phân biệt cá thể này với cá thể khác, luật kết hợp, tìm xu hướng, phân loại cá thể trong một tập hợp, phân cụm gộp nhóm các cá thể giống nhau, phân tích tìm ra cá thể ngoại lai và sự khác biệt đối với phần đông các cá thể khác, v.v...

Ngoài ra, tri thức còn là các chức năng tích hợp, đa chức năng và khai phá ở nhiều mức độ khác nhau.

- Loại kỹ thuật cần được sử dụng để giải quyết vấn đề

Bao gồm kỹ thuật theo hướng cơ sở dữ liệu, kỹ thuật kho dữ liệu (xử lý phân tích trực tuyến), các phương pháp học máy, các phương pháp thống kê, biểu diễn trực quan, mạng nơron nhân tạo, và các phương pháp khác.

- Loại ứng dụng cần được xây dựng, áp dụng cho vấn đề khai phá

Bao gồm các ứng dụng trong lĩnh vực bán lẻ, truyền thông, ngân hàng, phân tích lỗi, khai phá dữ liệu gen, phân tích thị trường chứng khoán, khai phá dữ liệu Web, phân tích Weblog.

Một công việc nữa cần được xác định là nhận thức rõ nhiệm vụ của bài toán khai phá dữ liệu là thuộc loại nào trong hai loại sau đây:

- Bài toán khai phá dữ liệu dạng mô tả

Nhiệm vụ của bài toán dạng này là tìm ra các mẫu mô tả dữ liệu mà con người có thể hiểu được.

- Bài toán khai phá dữ liệu dạng tiên đoán

Sử dụng một vài biến để tiên đoán các giá trị chưa biết hoặc trong tương lai của các biến khác.

Các nhiệm vụ thường gặp của việc khai phá dữ liệu

- Phân loại: thuộc loại bài toán tiên đoán

- Phân cụm: thuộc loại bài toán mô tả
- Phát hiện luật kết hợp: thuộc loại bài toán mô tả
- Phát hiện mẫu dạng liên tục: thuộc loại bài toán mô tả
- Bài toán hồi quy: thuộc loại bài toán tiên đoán
- Phát hiện sự khác biệt: thuộc loại bài toán tiên đoán

1.3 Các bài toán và phương pháp cơ bản trong khai phá dữ liệu

Định nghĩa bài toán phân loại

- Cho một tập các bản ghi được gọi là tập huấn luyện, mỗi bản ghi chứa một tập các thuộc tính, một thuộc tính trong đó gắn nhãn phân loại được gọi là thuộc tính lớp.
- Nhiệm vụ của bài toán phân loại là tìm ra một mô hình thể hiện thuộc tính lớp là một hàm của giá trị của các thuộc tính khác
- Sau khi tìm được mô hình thích hợp nhất cho bài toán, mục đích cuối cùng là áp dụng mô hình (hàm tìm được) đó để tiên đoán các bản ghi chưa được biết đến trước đó thuộc lớp nào một cách càng chính xác càng tốt.
- Một tập bản ghi kiểm thử được dùng để xác định độ chính xác của mô hình. Thông thường, một tập dữ liệu được đưa ra sẽ được chia thành tập huấn luyện và tập kiểm thử, tập huấn luyện được dùng để xây dựng mô hình và tập kiểm thử được dùng để kiểm tra.

Một ví dụ minh họa cho bài toán phân loại: Cho tập các bản ghi được coi là tập huấn luyện như hình vẽ dưới đây

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Trong đó thuộc tính **Cheat** là thuộc tính phân lớp, thuộc tính Tid không có ý nghĩa trong việc huấn luyện mô hình. Các bản ghi của tập huấn luyện này được sử dụng để tìm ra sự phụ thuộc giữa thuộc tính phân lớp và các thuộc tính còn lại (hàm phụ thuộc). Khi tìm được sự phụ thuộc này (hay còn gọi là bộ phân lớp) chúng ta nói đã huấn luyện xong mô hình phân lớp.

Mô hình phân lớp tìm được sẽ được xác định tính chính xác thông qua việc áp dụng mô hình phân lớp cho một bộ dữ liệu.

Refund	Marital Status	Taxable Income	Cheat
No	Single	75K	?
Yes	Married	50K	?
No	Married	150K	?
Yes	Divorced	90K	?
No	Single	40K	?
No	Married	80K	?

Giá trị của thuộc tính **Cheat** sẽ được tính sau khi đưa mỗi bản ghi qua mô hình phân lớp, giá trị đó sẽ được so sánh với giá trị thực của thuộc tính trong bộ dữ liệu được cho trước, để xác định tính chính xác của mô hình phân lớp.

Mô hình tìm được sẽ được sử dụng để phân loại các bản ghi mới với những giá trị thuộc tính (ngoại trừ thuộc tính phân lớp) đã biết, để phục vụ nhu cầu của người sử dụng. Với ví dụ minh họa này, với những giá trị sẵn có của một người như tình trạng hôn nhân, thu nhập tính thuế và thông tin có hoàn trả thuế hay không, mô hình phân loại bản ghi đó là thông tin giả hay thật.

Định nghĩa bài toán phân cụm


Cho một tập các điểm dữ liệu, mỗi điểm có một tập thuộc tính và có một độ đo sự tương đồng giữa chúng để phân cụm sao cho:

- Những điểm dữ liệu trong cùng một cụm thì có sự tương đồng cao, nhiều hơn với các điểm khác.
- Những điểm dữ liệu trong các cụm riêng rẽ thì ít tương đồng hơn các điểm thuộc cùng một cụm.

Các độ đo sự tương đồng có thể kể đến

- Khoảng cách Öclit nếu các thuộc tính là giá trị liên tục
- Các độ đo khác theo từng bài toán và lĩnh vực

Mô tả một phân cụm dựa trên khoảng cách Öclit trong không gian 3 chiều được thể hiện trong hình vẽ dưới đây



Nhìn và hình vẽ thấy rõ các điểm được phân thành 3 cụm thể hiện bởi ba màu đỏ, nâu và xanh sao cho khoảng cách giữa hai điểm bất kỳ trong cùng một cụm là nhỏ nhất có thể và khoảng cách giữa hai điểm bất kỳ của hai cụm khác nhau là lớn nhất có thể.

Định nghĩa bài toán phát hiện luật kết hợp

Cho một tập các bản ghi, mỗi bản ghi đều có chứa một số mặt hàng nằm trong một tập các mặt hàng cho sẵn. Nhiệm vụ của bài toán này là sản xuất ra các luật phụ thuộc, thể hiện sự tiên đoán về sự xuất hiện một mặt hàng này dựa trên sự xuất hiện của các mặt hàng khác.

Bài toán này xuất phát từ nhu cầu thực tế khi con người đi mua bán ở các siêu thị. Một ví dụ mô tả bài toán này như sau: Cho thông tin về các giao dịch mua bán được thể hiện trong bảng dưới đây gồm 2 cột: mã giao dịch và các mặt hàng mua bán trong mỗi giao dịch. Các luật tìm được: {Milk} --> {Coke}; {Diaper, Milk} --> {Beer} có nghĩa là nếu một người mua sữa (Milk) thì nhiều khả năng sẽ mua Coca cola (Coke); Và nếu mua tã và sữa (Diaper, Milk) thì nhiều khả năng sẽ mua bia (Beer).

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Bài toán phân loại cho dữ liệu hồi quy

Định nghĩa bài toán

Dự đoán một giá trị của một biến hồi quy dựa trên giá trị của các biến khác với giả định mô hình phụ thuộc là tuyến tính hoặc phi tuyến.

Bài toán này được sử dụng rất nhiều trong nghiên cứu thống kê, và các lĩnh vực của mạng nơron.

Ví dụ của bài toán

- Dự đoán số lượng bán ra của các sản phẩm mới dựa trên chi phí cho việc quảng cáo
- Dự đoán vận tốc của gió như là một hàm số của nhiệt độ, độ ẩm, áp suất...vv
- Tiên đoán theo chuỗi thời gian của chỉ số thị trường chứng khoán

Phát hiện sự sai lệch hay dị thường

Định nghĩa bài toán: Phát hiện những sai phạm đáng kể từ những hành vi bất thường

Ví dụ của bài toán

- Phát hiện xâm phạm thẻ tín dụng: dùng thẻ tín dụng của người khác để mua bán trên mạng
- Phát hiện xâm nhập mạng lưới máy tính để thực hiện các hoạt động không bình thường

Khai phá dữ liệu và Nguyên lý quy nạp

Trong phần này ta xem xét sự liên hệ giữa khai phá dữ liệu và nguyên lý quy nạp và suy diễn. Trước hết ta phân biệt suy diễn và quy nạp.

Suy diễn thông thường đảm bảo tính xác thực của mệnh đề. Một ví dụ cho sự suy diễn này được thể hiện thông qua ba mệnh đề sau:

1. Tất cả các con ngựa đều là loài động vật có vú
2. Tất cả các loài động vật có vú đều có phổi
3. Vì thế, tất cả các loài ngựa đều có phổi

Trong khi đó, suy diễn quy nạp thêm thông tin (chưa chắc đã xác thực). Một ví dụ về suy diễn quy nạp như sau:

1. Tất cả các con ngựa được quan sát từ trước đến nay đều có phổi
2. Vì vậy, tất cả các con ngựa đều có phổi.

Suy diễn theo kiểu quy nạp thường gặp vấn đề: từ các thực tế có thực, chúng ta có thể suy diễn ra một mô hình sai hoặc không đúng trong tất cả các trường hợp. Một ví dụ điển hình cho vấn đề này được thể hiện qua các mệnh đề sau: Tất cả các con thiên nga ở châu Âu đều màu trắng

Dùng suy diễn theo kiểu quy nạp suy ra rằng: tất cả các con thiên nga đều màu trắng như một quy luật chung. Nhưng chúng ta thấy rằng còn loại thiên nga ở châu Úc và loại thiên nga đen

nữa. Như vậy kết quả của suy diễn quy nạp là sai trong một số trường hợp. Nguyên nhân việc suy diễn sai ở đây là do việc chọn tập các mẫu quan sát không ngẫu nhiên và không đại diện cho tập toàn bộ cá thể.


Một ví dụ khác: phân biệt các thùng chứa của Mỹ và của Irắc.

- Để thực hiện việc này chúng ta dùng phương pháp phân loại sử dụng một cơ sở dữ liệu các hình ảnh, và phân chúng ra thành tập huấn luyện và tập kiểm thử, mô hình phân loại sẽ được xây dựng dựa trên tập huấn luyện.
- Kết quả của phương pháp này sẽ cho độ chính xác của việc tiên đoán tốt chỉ trên tập kiểm thử, còn sẽ cho kết quả tồi trên các bức ảnh độc lập khác.
- Nguyên nhân của việc cho độ chính xác tồi khi phân loại các hình ảnh độc lập là do các đặc điểm đặc biệt trên các bức ảnh đó.

1.4 Sự tích hợp của khai phá dữ liệu với cơ sở dữ liệu hay kho dữ liệu

Vai trò của khai phá dữ liệu đối với quá trình phát hiện tri thức từ dữ liệu (KDD)

được thể hiện trong hình vẽ dưới đây

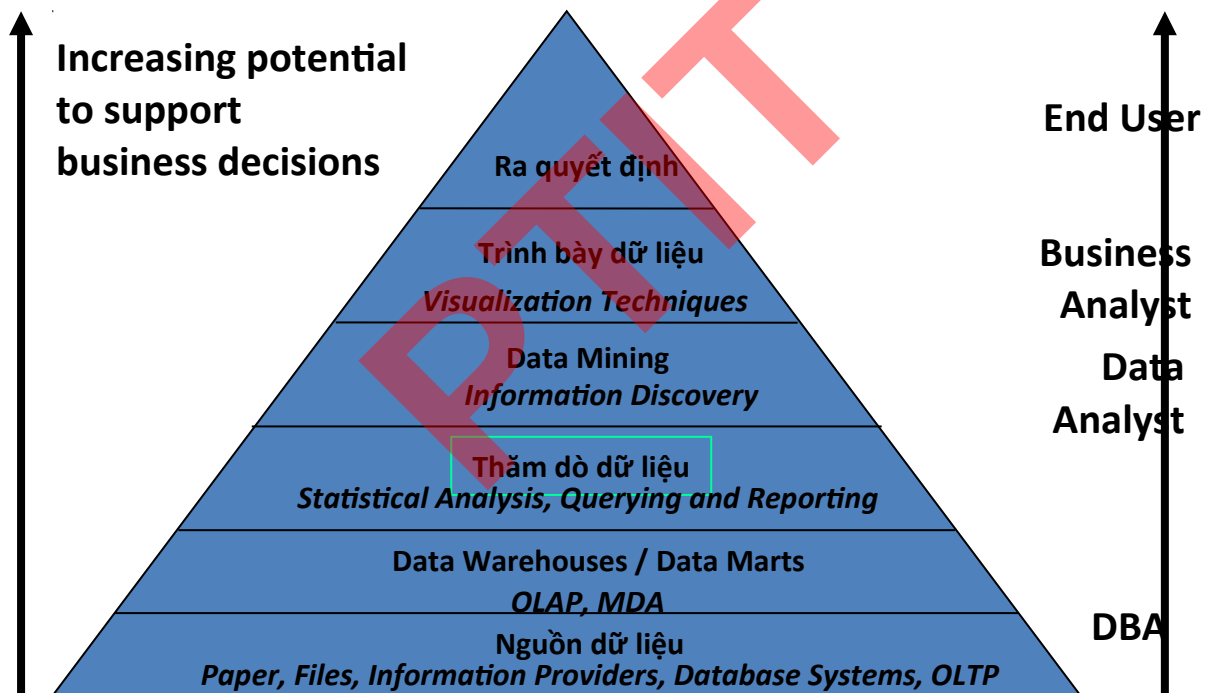


Các bước của quá trình phát hiện tri thức từ dữ liệu

- Học từ lĩnh vực ứng dụng: liên quan tới các tri thức liên quan trước đó và mục tiêu của ứng dụng
- Tạo một tập dữ liệu đích: cần phải lựa chọn dữ liệu cho vào tập dữ liệu này
- Quá trình tiền xử lý và làm sạch dữ liệu: có lẽ chiếm 60% công sức trong toàn bộ

- Chuyển đổi và thu hẹp dữ liệu: quá trình này liên quan tới việc tìm ra những đặc tính có ích, giảm biến và chiều của dữ liệu, tìm ra những phần tử đại diện bất biến
- Lựa chọn những chức năng của khai phá dữ liệu như tổng hợp, phân loại, phân loại cho dữ liệu liên tục, luật kết hợp, phân cụm
- Lựa chọn các thuật toán khai phá
- Khai phá dữ liệu: cần tìm kiếm các mẫu quan tâm
- Đánh giá các mẫu tìm được và biểu diễn tri thức thông qua các phương pháp trực quan, phương pháp chuyển đổi, loại bỏ các mẫu dư thừa, v.v..
- Sử dụng các tri thức phát hiện được cho mục đích khác của người sử dụng

Mối quan hệ giữa Khai phá dữ liệu và Tri thức kinh doanh được thể hiện trong tháp dưới đây



Trục bên trái của tháp thể hiện mức độ hỗ trợ cho việc ra quyết định của các nhà kinh doanh tăng dần của các công việc trong tháp tương ứng với mức đó. Trục bên phải của tháp thể hiện các vai trò của con người thực hiện công việc ở mức tương ứng của tháp.

Dữ liệu được xử lý ở các mức độ khác nhau từ thấp đến cao tính từ đáy đến đỉnh của tháp. Ở mức thấp nhất, nguồn dữ liệu được thu thập từ nhiều kênh khác nhau như từ các tài liệu, tập tin, nhà cung cấp thông tin, các hệ thống cơ sở dữ liệu, hệ thống xử lý giao dịch trực tuyến (OLTP). Sau đó, các dữ liệu được đưa vào kho dữ liệu hoặc các kho dữ liệu theo chiều để cung cấp xử lý

phân tích trực tuyến (OLAP), với quản trị dữ liệu đa chiều (MDA). Hai mức này được thực hiện bởi người quản trị hệ thống cơ sở dữ liệu. Tiếp tới các dữ liệu được thăm dò bằng các phương pháp phân tích thống kê, báo cáo và truy vấn và được khai phá để phát hiện ra thông tin bởi các nhà phân tích dữ liệu. Cuối cùng, dữ liệu sau khi được khai phá sẽ được trình bày sử dụng các kỹ thuật biểu diễn trực quan, kết quả của việc biểu diễn trực quan này sẽ được các người sử dụng cuối sử dụng trợ giúp cho việc ra quyết định.

Các loại dữ liệu cho khai phá dữ liệu có thể kể đến các loại sau

- Cơ sở dữ liệu quan hệ: đã được học trong học phần Cơ sở dữ liệu
- Kho dữ liệu
- Các cơ sở dữ liệu giao dịch
- Các cơ sở dữ liệu nâng cao và các kho chứa thông tin bao gồm c
 - o các cơ sở dữ liệu hướng đối tượng và cơ sở dữ liệu đối tượng quan hệ,
 - o cơ sở dữ liệu không gian,
 - o dữ liệu thời gian và chuỗi thời gian
 - o Cơ sở dữ liệu văn bản và đa phương tiện
 - o Các cơ sở dữ liệu thông tin bằng chữ và hỗn tạp
 - o Hệ thống trang Web trên toàn cầu

Các chuyên ngành khác liên quan tới khai phá dữ liệu

- Các công nghệ cơ sở dữ liệu
- Các kỹ thuật học máy
- Thống kê
- Khoa học thông tin
- Biểu diễn trực quan và các chuyên ngành khác.

So sánh khai phá dữ liệu với phân tích thống kê

Phân tích thống kê	Khai phá dữ liệu
phù hợp với các loại dữ liệu có cấu trúc và dạng số	Phù hợp với tập dữ liệu lớn, dữ liệu của thế giới thực, có thể có nhiều giá trị bị mất, dữ liệu tồn tại trước đó không phải do người sử

	dụng tạo ra
Hoàn toàn hướng dữ liệu – không liên quan tới tri thức miền giá trị cả dữ liệu	Hiệu quả và khả năng mở rộng về kích cỡ của thuật toán là quan trọng đối với việc khai phá
Phiên dịch kết quả khó và không rõ ràng	Dữ liệu không tĩnh- có xu hướng cập nhật thường xuyên
Cần sự hướng dẫn của chuyên gia sử dụng	Cần các phương pháp thu thập dữ liệu hiệu quả có sẵn để dùng

So sánh khai phá dữ liệu với cơ sở dữ liệu

Để so sánh chúng ta xem xét báo cáo cơ sở dữ liệu thường trả lời những truy vấn chứa các thông tin kiểu như sau:

- Lượng hàng bán được cho mỗi loại dịch vụ của các tháng trước đó
- Lượng hàng bán được cho mỗi loại dịch vụ được gộp nhóm theo từng giới tính của khách hàng hoặc nhóm tuổi của khách hàng
- Liệt kê danh sách các khách hàng không dùng dịch vụ liên tục của công ty

Những câu hỏi trả lời được bởi khai phá dữ liệu kiểu như sau:

- Đặc điểm chung của các khách hàng không dùng liên tục dịch vụ của công ty và sự khác nhau giữa họ và các khách hàng có dùng dịch vụ liên tục
- Loại người dùng bảo hiểm mô tô nào là khách hàng tiềm năng cho loại bảo hiểm đồ đạc trong nhà.

So sánh khai phá dữ liệu với công nghệ kho dữ liệu


- Kho dữ liệu là một kho lưu trữ dữ liệu tập trung có thể được truy vấn cho các lợi ích kinh doanh
- Công nghệ kho dữ liệu có thể
 - o Trích lọc các dữ liệu tác nghiệp được lưu trữ
 - o Giải quyết được sự không đồng nhất giữa các định dạng dữ liệu văn bản khác nhau
 - o Tích hợp dữ liệu trong toàn bộ doanh nghiệp, không phụ thuộc vào vị trí, định dạng hoặc các yêu cầu về truyền thông giao tiếp
 - o Phối hợp với các thông tin của chuyên gia và thông tin bổ sung từ bên ngoài
- Xử lý phân tích trực tuyến là chức năng do công nghệ kho dữ liệu cung cấp
- Mô hình dữ liệu nhiều chiều cũng thuộc công nghệ kho dữ liệu

- Các thao tác cơ bản của công nghệ kho dữ liệu bao gồm:
 - o Cuộn lên (roll-up)
 - o Khoan sâu xuống (drill-down)
 - o Cắt dọc (Slice) và cắt ngang (dice)
 - o Quay (Rotate)

Kiến trúc của một mô tơ phân tích trực tuyến (OLAM)

được thể hiện như hình vẽ dưới đây

Mô hình OLAM bao gồm 4 tầng như hình vẽ trên: Kho lưu trữ dữ liệu, CSDL đa chiều, OLAP/OLAM và giao diện với người sử dụng. Giữa mỗi tầng có một giao diện xử lý (API): tầng 1 và 2 là API của cơ sở dữ liệu (Database API), giữa tầng 2 và 3 là API của khối dữ liệu (Data Cube API), giữa tầng 3 và 4 là API giao diện đồ họa với người sử dụng (User GUI API). Dữ liệu của mỗi tầng được lưu trữ dưới dạng CSDL và kho dữ liệu ở tầng 1, CSDL đa chiều ở tầng 2 và dạng của OLAP và OLAM ở tầng 3, tầng 4 là tầng cho người sử dụng (NSD). Ở tầng 4 NSD đưa vào hệ thống những câu truy vấn khai phá và thông qua các mô tơ OLAP và OLAM nhận được kết quả khai phá thông qua giao diện đồ họa. Các mũi tên giữa các khối trong hình vẽ thể hiện sự tương tác một chiều (ứng với mũi tên một chiều) hay tương tác qua lại (ứng với mũi tên hai chiều) của các bộ phận trong hệ thống với công việc chính là các nhãn gắn trên mũi tên đó. Ngoài dữ liệu ra, tầng 2 còn có sự góp phần của siêu dữ liệu giúp bổ sung thông tin cho các dữ liệu chính trong hệ thống.



So sánh Cơ sở dữ liệu, xử lý phân tích trực tuyến và khai phá dữ liệu

được thể hiện theo các tiêu chí so sánh bao gồm

- Nhiệm vụ:
 - o Trích xuất dữ liệu chi tiết và tổng quát của cơ sở dữ liệu (DBMS)
 - o Tóm tắt, xác định xu hướng và dự đoán của hệ thống xử lý phân tích trực tuyến (OLAP)
 - o Khai phá dữ liệu từ những thông tin tiềm ẩn bên trong dữ liệu của khai phá dữ liệu (DM)
- Loại kết quả:
 - o Thông tin của DBMS
 - o Phân tích của OLAP
 - o Chi tiết bên trong và dự đoán của DM
- Phương pháp:
 - o Suy diễn bằng các hỏi các câu hỏi và kiểm định với dữ liệu của DBMS
 - o Mô hình dữ liệu đa chiều, tích hợp và thống kê của OLAP

- Quy nạp bằng cách xây dựng mô hình, áp dụng nó với dữ liệu mới và thu thập kết quả cho DM
- Các câu hỏi ví dụ:
 - DBMS có thể trả lời: Ai mua quỹ phúc lợi trong vòng 3 năm gần đây?
 - OLAP có thể trả lời: Thu nhập trung bình của những người mua quỹ phúc lợi theo từng vùng cho từng năm?
 - DM có thể trả lời: Ai sẽ mua quỹ phúc lợi trong 6 tháng tới và tại sao.
- Ví dụ về dữ liệu thời tiết trong cơ sở dữ liệu được cho trong bảng sau

Day	outlook	temperature	humidity	windy	play
1	sunny	85	85	false	no
2	sunny	80	90	true	no
3	overcast	83	86	false	yes
4	rainy	70	96	false	yes
5	rainy	68	80	false	yes
6	rainy	65	70	true	no
7	overcast	64	65	true	yes
8	sunny	72	95	false	no
9	sunny	69	70	false	yes
10	rainy	75	80	false	yes
11	sunny	75	70	true	yes
12	overcast	72	90	true	yes
13	overcast	81	75	false	yes
14	rainy	71	91	true	no

- Với DBMS khi truy vấn trong DBMS chứa trong bảng trên ta có thể trả lời những câu hỏi như :
 - Nhiệt độ của ngày Chủ nhật là bao nhiêu? {85, 80, 72, 69, 75}
 - Những ngày nào có độ ẩm nhỏ hơn 75? {6, 7, 9, 11}
 - Những ngày nào có nhiệt độ lớn hơn 70? {1, 2, 3, 8, 10, 11, 12, 13, 14}
 - Những ngày nào có nhiệt độ lớn hơn 70 và độ ẩm lớn hơn 75? {11}

- Với OLAP ta có thể tạo ra mô hình dữ liệu đa chiều (**Multidimensional Model**) hay còn gọi là khối dữ liệu (**Data Cube**).

- o VD có sử dụng các chiều : **time**, **outlook** và **play** ta có thể tạo ra được mô hình sau

9 / 5	sunny	rainy	overcast
Week 1	0 / 2	2 / 1	2 / 0
Week 2	2 / 1	1 / 1	2 / 0

- Với DM sử dụng phương pháp phân loại bằng cây quyết định ID3 dữ liệu sẽ được biểu diễn dưới dạng cây quyết định như sau

- o outlook = sunny
 - humidity = high: no
 - humidity = normal: yes
 - o outlook = overcast: yes
 - o outlook = rainy
 - windy = true: no
 - windy = false: yes

1.5 Ứng dụng của kho dữ liệu và khai phá dữ liệu

Ứng dụng của bài toán phân lớp (phân loại)

1. Sử dụng trong tiếp thị trực tiếp:

- Mục đích: Phân loại khách hàng để xác định nhóm khách hàng tiềm năng thích mua những sản phẩm máy di động thế hệ mới nhất. Nhờ đó, các nhân viên tiếp thị không tốn tiền gửi thư cho những khách hàng không tiềm năng, chỉ gửi cho nhóm khách hàng tiềm năng này, để tiết kiệm chi phí.
- Cách tiếp cận cho ứng dụng này như sau
 - Sử dụng dữ liệu của một sản phẩm tương tự được giới thiệu trước đó
 - Ta biết được những khách hàng nào mua và những khách hàng nào không mua hàng. Quyết định $\{buy, don't\ buy\}$ chỉ ra *thuộc tính lớp*.
 - Thu thập các thông tin về nhân khẩu học, phong cách sống, các thông tin liên quan tới việc giao tiếp với công ty của khách hàng

- Công việc của khách hàng, nơi họ sống, số tiền họ kiếm được, v.v...
- Sử dụng thông tin này như là các thuộc tính đầu vào để huấn luyện một mô hình phân lớp.

2. Sử dụng trong phát hiện lừa gạt

- Mục đích: Tiên đoán các trường hợp lừa gạt trong các giao dịch bằng thẻ tín dụng.
- Cách tiếp cận:
 - Dùng các thông tin của giao dịch bằng thẻ và các thông tin về tài khoản của người dùng như các thuộc tính như khi nào khách hàng mua, anh ta mua cái gì, tần suất anh ta trả tiền đúng hạn v.v..
 - Gán nhãn các giao dịch trong quá khứ như những giao dịch gian lận và không gian lận. Điều này xác định thuộc tính lớp.
 - Huấn luyện một mô hình cho việc phân lớp của các giao dịch.
 - Sử dụng mô hình này để phát hiện ra gian lận bằng cách quan sát những giao dịch bằng thẻ của một tài khoản.

3. Sử dụng trong việc kiểm tra xu hướng giảm số lượng khách hàng

- Mục đích: Tiên đoán xem liệu có để một khách hàng rơi vào tay một công ty cạnh tranh hay không.
- Cách tiếp cận:
 - Sử dụng các bản ghi chi tiết của các giao dịch của từng khách hàng trong hiện tại và quá khứ để tìm các thuộc tính như tần suất các cuộc gọi của khách hàng, khách hàng gọi ở đâu, thời điểm nào khách hàng hay gọi nhất, tình hình tài chính và tình trạng hôn nhân của khách hàng v.v...
 - Gán nhãn cho khách hàng gồm khách hàng lâu năm và không lâu năm.
 - Tìm ra mô hình để phân loại khách hàng lâu năm

4. Sử dụng trong phân loại các vật thể khi khảo sát bầu trời

- Mục đích: Tiên đoán phân loại các vật thể trên bầu trời (là sao hay thiên hà), dựa trên những hình ảnh thu được từ kính thiên văn. Ví dụ từ 3000 bức ảnh với 23,040 x 23,040 pixels/ảnh.
- Cách tiếp cận:
 - Phân đoạn ảnh.
 - Đo các thuộc tính ảnh, thường thì 40 thuộc tính cho mỗi đối tượng ảnh

- Thiết lập mô hình phân lớp dựa trên những thuộc tính này

Ứng dụng của bài toán phân cụm

1. Phân mảnh thị trường

- Mục đích: chia nhỏ thị trường thành các tập con riêng biệt mà bất kỳ tập con nào cũng có thể được lựa chọn như là một mục tiêu tiếp thị.
- Cách tiếp cận:
 - Thu thập các thuộc tính khác nhau của khách hàng dựa trên các thông tin liên quan đến lối sống, khu vực sinh sống.
 - Tìm các cụm khách hàng tương đồng.
 - Đánh giá chất lượng phân cụm bằng cách quan sát kiểu mua hàng của những khách hàng thuộc cùng một cụm với các khách hàng thuộc cụm khác.

2. Phân cụm tài liệu

- Mục đích: Tìm ra những nhóm văn bản có sự tương đồng lẫn nhau dựa trên các thuật ngữ quan trọng xuất hiện trong văn bản.
- Cách tiếp cận:
 - Xác định những thuật ngữ thường xuất hiện trong văn bản. Chỉ ra độ tương đồng dựa trên tần suất xuất hiện các khái niệm khác nhau. Dùng nó để phân cụm.
- Kết quả đạt được: Trích lọc thông tin có thể dùng kết quả phân cụm này để liên hệ tới một văn bản mới hoặc tìm kiếm các từ thuật ngữ trong một văn bản đã được phân cụm.

Ứng dụng của bài toán phát hiện luật kết hợp

1. Tiếp thị và Tăng doanh số Bán Hàng

- Giả sử phát hiện ra luật sau : $\{ Bagels, \dots \} \rightarrow \{ Potato\ Chips \}$
- Potato Chips được coi là hệ quả của việc mua Bagels, điều này có thể được dùng để xác định công việc cần thực hiện để tăng doanh số bán hàng lên.
- Bagels được gọi là điều kiện trước và nó có thể được dùng để xác định xem những sản phẩm nào trong siêu thị có thể bị ảnh hưởng nếu dừng bán Bagels.
- Bagels là điều kiện trước và Potato chips là hệ quả sau . Điều này xác định rằng các sản phẩm cần được bán cùng với Bagels để tăng doanh số bán hàng là Potato chips.

2. Quản lý các kệ hàng trong siêu thị

- Mục đích: Phát hiện ra các luật kết hợp để xác định các mặt hàng được mua cùng nhau bởi nhiều khách hàng. Nhờ đó có thể sắp xếp các kệ hàng, gian hàng trong siêu thị một cách hợp lý nhất.
- Cách tiếp cận: xử lý các dữ liệu trọng điểm được thu thập từ việc nhận dạng qua mã quét hàng lúc thanh toán để tìm mối quan hệ giữa các mặt hàng.
- Thường xuất hiện một luật: Nếu một khách hàng mua tã và sữa, thì nhiều khả năng anh ấy sẽ mua bia.

Dự đoán một giá trị của 1 biến liên tục dựa trên giá trị của các biến khác, Giả định 1 mô hình tuyến tính hay phi tuyến của các phụ thuộc

Những vấn đề chính trong lĩnh vực công nghệ kho dữ liệu và khai phá dữ liệu

Một trong những vấn đề cần giải quyết liên quan tới sự đa dạng về loại dữ liệu được dùng trong khai phá cũng như được tích hợp vào kho dữ liệu bao gồm

- Xử lý loại dữ liệu quan hệ và dữ liệu loại tổng hợp và phức tạp
- Khai phá các thông tin từ những cơ sở dữ liệu hỗn tạp và hệ thống lưu trữ thông tin trên oàn cầu như trên hệ thống trang web toàn cầu (www)

Thứ hai là các vấn đề liên quan tới ứng dụng và các ảnh hưởng về mặt xã hội bao gồm

- Các ứng dụng các tri thức khai phá được liên quan tới các công cụ khai phá dữ liệu cho các lĩnh vực cụ thể; Trả lời các câu truy vấn thông minh; Kiểm soát xử lý và ra quyết định
- Tích hợp các tri thức phát hiện được với các tri thức đã tồn tại sẵn có. Đây chính là bài toán trộn tri thức.
- Bảo đảm an toàn dữ liệu, toàn vẹn và riêng tư của dữ liệu

Câu hỏi ôn tập chương 1

1.1 Khai phá dữ liệu là gì? Trong câu trả lời của bạn, hãy chỉ ra những điều sau:

- (a) Nó là một sự chuyển đổi đơn giản của công nghệ phát triển từ cơ sở dữ liệu, thống kê, và học máy?
- (b) Giải thích sự tiến triển của công nghệ cơ sở dữ liệu đã dẫn đến khai phá dữ liệu như thế nào.
- (c) Mô tả các bước liên quan đến khai phá dữ liệu khi được xem như một quá trình phát hiện tri thức

1.2 Trình bày một ví dụ trong đó khai phá dữ liệu rất quan trọng đối với sự thành công của một doanh nghiệp. Nêu các chức năng của khai phá dữ liệu mà doanh nghiệp này cần. Chúng có thể được thực hiện thay thế bằng việc xử lý truy vấn dữ liệu hoặc phân tích thống kê đơn giản được không?

1.3 Giả sử nhiệm vụ của bạn là kỹ sư phần mềm tại Học viện công nghệ bưu chính viễn thông là thiết kế một hệ thống khai thác dữ liệu để nghiên cứu cơ sở dữ liệu các khóa học đại học, bao gồm các thông tin sau: tên, địa chỉ và trạng thái (ví dụ: đại học hoặc sau đại học) của từng sinh viên, các khóa học được thực hiện và điểm trung bình tích lũy (GPA). Hãy mô tả kiến trúc bạn sẽ chọn. Mục đích của mỗi thành phần của kiến trúc này là gì?

1.4 Kho dữ liệu khác với cơ sở dữ liệu như thế nào? Chúng giống nhau như thế nào?

1.5 Mô tả ngắn gọn các hệ thống và ứng dụng của cơ sở dữ liệu nâng cao sau: cơ sở dữ liệu quan hệ đối tượng, cơ sở dữ liệu không gian, cơ sở dữ liệu văn bản, cơ sở dữ liệu đa phương tiện, dữ liệu luồng, World Wide Web.

1.6 Định nghĩa từng chức năng của khai phá dữ liệu sau: phân tích đặc điểm, sự khác biệt, tính kết hợp và phân tích tương quan, phân loại, dự đoán, phân cụm và phân tích tiến hóa. Đưa ra ví dụ về từng chức năng khai phá dữ liệu, sử dụng cơ sở dữ liệu thực tế mà bạn đã quen thuộc.

1.7 Sự khác nhau giữa phân tích sự khác biệt và phân loại là gì? Giữa phân tích đặc tính và phân cụm? Giữa phân loại và dự đoán? Đối với mỗi cặp nhiệm vụ, chúng giống nhau như thế nào?

1.8 Dựa trên quan sát của bạn, mô tả một loại tri thức khác có thể cần phải được phát hiện bằng phương pháp khai phá dữ liệu nhưng chưa được liệt kê trong chương này. Nó có cần phương pháp khai phá hoàn toàn khác với phương pháp được nêu trong chương này không?

1.9 Liệt kê và mô tả năm yếu tố gốc (primitives) để xác định một nhiệm vụ khai phá dữ liệu.

1.10 Mô tả lý do tại sao phân cấp khái niệm hữu ích trong khai phá dữ liệu.

1.11 Các thành phần ngoại lai (outliers) thường bị loại bỏ là tiếng ồn. Tuy nhiên, rác của một người có thể là kho báu của người khác. Ví dụ: các trường hợp ngoại lệ trong giao dịch thẻ tín dụng có thể giúp chúng tôi phát hiện việc sử dụng thẻ tín dụng gian lận. Lấy phát hiện gian lận làm ví dụ, đề xuất hai phương pháp có thể được sử dụng để phát hiện các ngoại lệ và thảo luận phương pháp nào đáng tin cậy hơn.

1.12 Các ứng dụng gần đây đặc biệt chú ý đến luồng dữ liệu không gian và thời gian. Luồng dữ liệu không gian và thời gian chứa thông tin không gian thay đổi theo thời gian và có dạng dữ liệu luồng (tức là luồng dữ liệu vào và ra như các luồng vô hạn).

(a) Trình bày ba ví dụ ứng dụng của luồng dữ liệu không gian và thời gian.

(b) Thảo luận xem loại kiến thức có ích nào có thể được khai phá từ các luồng dữ liệu như vậy, với thời gian và tài nguyên giới hạn.

(c) Xác định và thảo luận những thách thức chính trong khai phá dữ liệu không gian thời gian.

(d) Sử dụng một ví dụ ứng dụng, phác họa một phương pháp để khai phá một loại tri thức từ dữ liệu luồng như vậy hiệu quả.

1.13 Mô tả sự khác biệt giữa các cách tiếp cận sau đây cho việc tích hợp dữ liệu của hệ thống khai phá với một cơ sở dữ liệu hoặc hệ thống kho dữ liệu: không có ghép nối, ghép nối lỏng lẻo, ghép nối khá chặt và ghép nối chặt chẽ. Hãy phát biểu cách tiếp cận bạn nghĩ là phổ biến nhất và nêu lý do tại sao.

1.14 Mô tả ba thách thức đối với khai phá dữ liệu liên quan đến phương pháp khai phá dữ liệu và các vấn đề tương tác với người dùng.


1.15 Những thách thức chính khi khai phá một lượng lớn dữ liệu (như hàng tỷ bộ) so với khai phá một lượng nhỏ dữ liệu (chẳng hạn như bộ dữ liệu gồm vài trăm bộ)?

1.16 Phác thảo các thách thức nghiên cứu chính về khai phá dữ liệu trong một miền ứng dụng cụ thể, chẳng hạn như phân tích dữ liệu luồng/cảm biến, phân tích dữ liệu không gian và thời gian hoặc lĩnh vực tin sinh học

Chương 2: Các công nghệ và kỹ thuật tích hợp cơ sở dữ liệu

2.1 Giới thiệu Mô hình dữ liệu mở rộng XML

Phần đầu tiên của môn học sẽ đi vào xem xét các kỹ thuật chuyển đổi và tích hợp dữ liệu vào kho dữ liệu từ các nguồn dữ liệu khác nhau. Trước hết xem xét kiến trúc đa tầng của kho dữ liệu và khai phá dữ liệu thể hiện trong hình vẽ dưới đây



Dữ liệu được thu thập từ nhiều nguồn khác nhau trong đó có cơ sở dữ liệu tác nghiệp và các nguồn dữ liệu khác. Chúng được trích lọc, chuyển đổi và tải vào một nơi lưu trữ được gọi là kho dữ liệu. Ngoài ra dữ liệu còn có thể tích hợp, làm mới để đưa vào kho dữ liệu, sau đó được tổ chức lại để phục vụ cho OLAP và các công cụ đầu cuối của người sử dụng bao gồm công cụ phân tích, truy vấn, báo cáo và khai phá dữ liệu.

Tại thời điểm này chúng ta bắt đầu từ nguồn dữ liệu, ngoài các cơ sở dữ liệu quan hệ được học ở môn học trước, chúng ta xem xét một loại dữ liệu cũng tương đối phổ biến hiện nay là mô hình dữ liệu mở rộng XML.

Giới thiệu về ngôn ngữ XML (Extensible Markup Language)


- Là ngôn ngữ đánh dấu mở rộng, về tính mở rộng thì giống với ngôn ngữ đánh dấu html đã được làm quen từ trước.
- Do tổ chức World Wide Web Consortium (W3C) giới thiệu Version 1.0 vào năm 1998

- Là một ngôn ngữ dùng để miêu tả dữ liệu, chứ không phải hướng dẫn một hệ thống xử lý dữ liệu.
- Cung cấp một công cụ khá mạnh cho việc tích hợp dữ liệu và theo kiểu hướng dữ liệu.
- Giới thiệu một cơ chế xử lý mới và yêu cầu các cách suy nghĩ mới để phát triển web.
- Là một ngôn ngữ siêu đánh dấu nên có một tập các luật để tạo ra những thẻ ngữ nghĩa dùng để miêu tả dữ liệu.
- XML là một ngôn ngữ có khả năng mở rộng khác với HTML
 - o Với HTML, thẻ được sử dụng để đánh dấu tài liệu và cấu trúc của tài liệu HTML được ấn định trước.
 - o Những người sử dụng tài liệu HTML chỉ được sử dụng những thẻ đã được định nghĩa trước trong chuẩn HTML.
 - o XML cho phép người sử dụng định nghĩa thẻ và cấu trúc trong dữ liệu của mình.
- Sử dụng XML mang lại lợi ích bởi những đặc điểm sau
 - o XML có cấu trúc nên dễ học, dễ dùng
 - o Không phụ thuộc vào cấu hình nền phần cứng của hệ thống, cung cấp thông tin văn bản
 - o Là một chuẩn mở
 - o Độc lập với Ngôn ngữ
 - o DOM và SAX là tập các giao diện mở, độc lập với ngôn ngữ
 - o Sử dụng cho web

Một hệ thống XML điển hình

Hệ thống XML điển hình bao gồm các thành phần được thể hiện như hình vẽ dưới đây

Tài liệu XML



- Thành phần thứ nhất là Tài liệu XML chứa nội dung của văn bản cần thể hiện bằng ngôn ngữ XML
- Thành phần thứ hai là Định dạng kiểu tài liệu XML-DTD, thành phần này xác định cấu trúc và định dạng của văn bản. Đây chính là một thành phần thao tác.
- Thành phần thứ ba là Bộ Phân tích cú pháp XML dùng để xử lý trộn nội dung của văn bản và cấu trúc của văn bản để đưa ra văn bản XML hoàn chỉnh sau khi kiểm tra tính phù hợp của nội dung và định dạng.
- Thành phần thứ tư chính là ứng dụng XML (phân tích đầu ra của bộ phân tích cú pháp để đưa ra được một đối tượng duy nhất)

Sử dụng XML như thế nào?

XML khác biệt với HTML, nó có thể lưu trữ dữ liệu tách biệt khỏi văn bản HTML, chuyển đổi việc thể hiện dữ liệu sang định dạng khác thông qua việc tự định nghĩa cấu trúc DTD.

Cú pháp của XML

Xét một ví dụ văn bản XML đơn giản như sau

```
<?xml version="1.0"?>
```

```
<note>
```

```
<to>Tan Siew Teng</to>
```

```
<from>Lee Sim Wee</from>
<heading>Reminder</heading>
<body>Don't forget the Golf Championship this weekend!</body>
</note>
```

Ta hiểu ý nghĩa của mỗi dòng trong văn bản XML trên như sau

- Dòng đầu tiên trong tài liệu : khai báo XML version 1.0, dòng này luôn luôn phải có vì nó xác định phiên bản XML của văn bản.
- Trong trường hợp này tài liệu phù hợp với đặc tả 1.0 của XML <?xml version="1.0"?>
- Dòng tiếp theo xác định phần tử đầu tiên của tài liệu (gọi là phần tử gốc hay **root**) <note>
- Bốn dòng tiếp theo định nghĩa 4 phần tử con của **root** là **to**, **from**, **heading** và **body**

```
<to>Tan Siew Teng</to>
<from>Lee Sim Wee</from>
<heading>Reminder</heading>
<body>Don't forget the Golf Championship this weekend!</body>
```

- Dòng cuối cùng định nghĩa sự kết thúc của phần tử **root** bằng thẻ </note>

Một phần tử XML có những đặc điểm sau đây

- Được cấu tạo bởi một thẻ bắt đầu hay thẻ mở, một thẻ kết thúc hay thẻ đóng và dữ liệu ở giữa

```
<Sport>Golf</Sport>
```

- Tên của một phần tử được thể hiện bằng các ký tự nằm trong thẻ (tags).
- Thẻ bắt đầu và kết thúc miêu tả dữ liệu trong phạm vi của nó, gọi là dữ liệu của một phần tử.

Ví dụ, phần tử XML sau là một phần tử có tên là <player> với dữ liệu là “Tiger Wood.”

```
<player>Tiger Wood</player>
```

Thẻ bao gồm 3 loại

- Thẻ mở: Trong ví dụ <Sport> là một thẻ mở. Nó xác định các kiểu của một phần tử và thuộc tính đặc tả có thể. Ví dụ sau thể hiện thẻ có thuộc tính đặc tả

```
<Player firstname="Wood" lastname="Tiger">
```

Trong đó tên của thẻ là **Player** với hai thuộc tính đặc tả là **firstname** với giá trị **Wood** và **lastname** với giá trị **Tiger**.